


lec 2Data Acquisition (Data Collection)

The process of gathering data and making it useful by filtering and cleaning it as per the business requirement.

هذه عملية جمع البيانات وتنظيمها وتنظيفها بحيث تكون مفيدة ومناسبة لاحتياجات المشروع أو المشكلة التي نريد حلها.

دنا قولنا ان البيانات التي نستخدمها في data science هي big data وبالتالي فهي متنوعة كبير

Variety



Structure

Unstructure

Semi-Structure

① Structured data. البيانات منظم

This is data that is organized in a clear and consistent format. Such as tables in a database - excel files. It is stored in rows and columns to make it easy to search and manipulate.

② unstructured data. البيانات غير منظم

data that has no specific format or clear way of organizing it.

ex. image, video,

③ Semi-Structured data.

← This is an intermediate type between structure and unstructure data,

meaning it contains some structure element elements, but not as fully as traditional DB.

• نوع وسطي بين البيانات المنظمة وغير منظمة
هذا JSON ، سجلات (logs)

raw data

Data preprocessing

← The data we collect is often unclean. it may

Contain errors, missing data, duplicates, or be in the wrong format, so we need to go through a data preprocessing stage.

هذه البيانات التي نجمعها عادة يتكون من نظيفة ، وعشان كذا لازم نعد بمرحلة الـ preprocessing

البيانات كل ما كانت اذخرف واذق ، كل ما كان النموذج الي هو عمله افضل واذق في التوقع .

basic data preprocessing techniques

data preprocessing is done using four main techniques

- (1) Data cleaning ✓ تنظيف
- (2) Data integration ✓ دمج
- (3) Data transformation تحويل
- (4) Data Reduction. تقليل

① Data cleaning:-

هذه عملية مهمة جدًا لضمان تحسين جودة البيانات قبل ما تستخدمها في

التحليل أو النمذجة. Data cleaning Step يمكن تقوله عليه

A) Remove duplicate or irrelevant observations.

أحيانًا أثناء تجميع البيانات، ممكن يحصل تكرار للقيم أو إدخال بيانات غير مفيدة.

مثال: تدخل اسم دولة مرتين بشكل مختلف (طريقين تحذان)

⇒ New Zealand ⇒ New Zealand

B) Fix structural errors.

هذه الأخطاء التي تحصل بسبب الكتابة الخاطئة أو اختلاف طريقة الإدخال.

ذو مثال كتابة التواريخ بـ format مختلفة.

أي كأنهم توحد المصيغة التي هي منطوقها بالبيانات.

(c) Filter unwanted outliers

الـ outliers هي القيم التي تبدا فيها بعيدة عن باقي القيم (الآتا) وقد يكون يأتى على التطبيق.

مستوى كل الـ outliers خط الكتل كانت غير منطقية

يبقى أفضل نسخها

مثلا 8 شخص عمرة 500 سنة ← مشا منطقى

(d) handle missing data.

During analysis of data, it is important to understanding why the missing value exist.

في بعض البيانات، قد يكون تلاقى cells فاصية بحاله أسباب مختلفة والحل يعتمد على سبب نقص البيانات. الحالات

① in case, the values were not recorded,

it becomes essential to fillup the values by guessing based on the other values in that columns and rows.

التقدير. This is called Imputation.

① يبقى لو القيم مفقودة بالصدفة (مثلا أحد نسي تسجيلها)

ممكن نطول نضبطها بناء على القيم التانية.

② if a value is missing because it doesn't exist.

↳ leave it empty or to add a third value like NA or NaN.

③ لو القيمة مفقودة لأنها لم توجد أصلاً كأنها مفقودة منطقياً لشيء معين
 ذي مثلاً "طول الطفل الأكبر" وهو أصلاً مفقود في المثال.
 وقتها يمكن تسمية الـ cell فاصلة أو نكتب فيها NaN.

③ in case, it is not possible to figure out the reason for the missing, then that particular value can be dropped.

هل يتم مسح الصف والعمود؟

→ (X) →

(E) Noisy data

هذه البيانات التي تحتوي على أخطاء أو معلومات غير دقيقة
 عشوائية تعالجها في طرق مختلفة ذى -

(a) binning methods (discretization)

is used to smooth sorted data values by consulting the values around.

وهو معناه إذا قمنا بتقسيم البيانات إلى مجموعات صغيرة (bins)
 وبعدها نستخدم طريقة من الطرق لدراسة

① bin means

مبني حسب المتوسط لكل bins ونعدل القيم بالمتوسط.

② smoothing by bin median

هـ بنحسب الوسيط لكل مجموعة ونستخدّمه بدل القيد الاصلية.

③ smoothing by bin boundaries

هـ نستوف أكبر قيمة واصغر قيمة وباقي القيم بنقاردهم بالأكبر والاصغر ونستوف هه اقرب لمن وثبت لها جيهها.

bin 1, 3, 4, 9, 15, 2, 2, 16

1, 1, 1, 16, 16, 1, 1, 16

min: 1

max: 16

نستوف 3 مثلاً اقرب لـ 1 وهه لـ 16 اكيد (1) بيقتا نبدلها بـ 1

Algorithm 8-

- 1- Sort the datasets
- 2- Partition the dataset to bins. (equal bins)
- 3- Calculate the arithmetic mean or median or replace by boundary (min or max value)
- 4- Replace each data element in each bin by the calculated mean / median / boundaries.

example \ Given data 8 18, 22, 6, 6, 9, 14, 20, 21, 12, 18, 18, 16
illustrate binning by Mean, median, boundary
replacement. Given bin depth = 3

Step 1: Sort the data

6, 6, 9, 12, 14, 16, 18, 18, 18, 20, 21, 22

Step 2: Partition the data into equal frequency bins.

• num of bins = N/d

num of element = 12

bin depth = 3

3 element

bin 15

$12/3 = 4$ bins

bin 1: 6, 6, 9

bin 2: 12, 14, 16

bin 3: 18, 18, 18

bin 4: 20, 21, 22

Step 3: Mean = sum of observations / num of observation

bin 1: $(6+6+9)/3 = 7$

bin 2: $(12+14+16)/3 = 14$

bin 3: $(18+18+18)/3 = 18$

bin 4: $(20+21+22)/3 = 21$

∴ Step 4: Replace each data element in each bin by the calculated mean.

bin 1: 7, 7, 7

bin 3: 18, 18, 18

mean.

bin 2: 14, 14, 14

bin 4: 21, 21, 21

binning using median

القيمة التي في النص

في حالة عدد element في ال bin

فردي

bin 1 6, 6, 6

لو عدد القيم زوجي

هنا يجب الرقمين التي في النص ونجدهم ونقسمهم على 2

bin 2 14, 14, 14

bin 3 18, 18, 18

bin 4 21, 21, 21

binning using boundary values

bin 1 8, 6, 6, 9

bin 3 18, 18, 18

bin 2 12, 12, 16

bin 4 20, 20, 22

(b) Regression الانحدار

is used to find a mathematical equation to fit the data to smooth out the noise.

هذه طريقة رياضية تستخدمها عشان نلأقي معادلة تناسب البيانات وتساعدنا نقلل ال noise التي فيها.

عندنا نوعين من الانحدار

① linear regression

② multiple linear regression.

① linear regression

is used to find the best line that fits two variables such that one predicts the other.

• هذه تستخدمه لو عندنا متغيرين (ذو عدد مساوات المتكافئة ودرجات الامتداد) ونحاول نرسم خط مستقيم يوضح العلاقة بينهم بحيث نقدر نتوقع قيمة متغيرة بناء على الثاني.

② Multiple linear regression

involves more than two variables.

• هنا بيكون عندنا اكثر من متغير، بنحاول نلاقى علاقة رياضية تربط كل المتغيرات ببعضها.

(c) clustering

This approach is useful for organizing similar data in groups or clusters.

• ينقسم البيانات لمجموعات متشابهة clusters بحيث كل مجموعة يكون فيها بيانات متشابهة.

• The outliers may be detected by clustering.

② Data integration

data acquired from multiple sources is integrated into a single centralized location.

هذه عبارة عن دمج بيانات من مصادر مختلفة مكان تبقى أكثر سمولاً

The most Common approaches to integrate data :-

هناك طرق عديدة لنقدن تستخدمها لسان دمج البيانات من مصادر مختلفة بحيث تبقى منظمة وأسهل في الاستخدام

① Data Consolidation ✓

② Data propagation ✓

③ Data Virtualization

④ Data Warehousing

دول التي يهملوا

الدكتور باذن الله

التفاصيل التي تحتكها افهمها

بست

① data Consolidation

Means to consolidate data from several separate sources into one data store, so that it is available to all the stakeholders to enable better decision making.

يجمع البيانات من مصادر مختلفة في مكان واحد، بحيث تكون متاحة لكل الناس التي يحتاجونها لسان يقدروا ينفذوا قرارات أفضل.

• The most common data Consolidation techniques are:

A) ETL (extract, transform, load)

يتم استخراج البيانات من مصادر مختلفة، بعد ذلك يتم تخزينها
تكون مفهومة (ترتيبها، تنظيفها، تجميعها) وبعد ذلك يتم تخزينها
في قاعدة بيانات مركزية أو في warehouse.

is the most widely used data consolidation technique.

(1) The data is first extracted from multiple Sources.

(2) then it is transformed into an understandable format by using various functions.

(aggregating, sorting, cleaning)

(3) then transfer it to a centralized store.

(B) Data Virtualization

هنا البيانات يتم فصل في مكانها الأصلي، لكن يتم عرضها للمستخدمين
كأنها مجمعة في مكان واحد من غير الحاجة لنقلها فعلياً.

the data stays in the original location.

(e) Data Warehousing.

• is the integration of data from multiple sources to centralized source to facilitate decision making, reporting and query handling.

(2) Data Propagation.

• في الطريقة دي، البيانات بيتم نسخها من مكان لمكان تاني (من المصدر للمكان المستهدف).

• involves copying data from one location (source) to another location (target location).

• These applications usually operate online and push data to the target location.

(3) Data Virtualization

(4) Data Warehousing.



③ Data transformation

بعد ما يجمع البيانات وننظفها، ممكن تفضل مش متناسقة أو مش جاهزة للاستخدام. عشان دأ، لازم نغير شكلها وتركيبها بحيث تبقى أسهل في التليل والاستخدام.

Data transformation may be Constructive destructive, aesthetic or structural.

• Constructive data transformation

involve adding, Copying, replicating data.

• Destructive

involve deleting fields and records.

• Aesthetic

involve standardizing salutions or street names.

• Structural

involve renaming, moving Com bining Columns in data base.

④ Data Reduction

it is the process of reducing the Volume of data such that data integrity is preserved.

يقال حجم البيانات كثير ما تفقد لأهميتها مهمة، يعني حتى بعد تقليلها النتائج اللي هتطلع هتفضل دسماهي.

Data mining

• هي العملية التي بنسختها ما عشان نستخرج معلومات مفيدة من الرقابة الكثير التي متخدمة.

• الهدف الاساسي من ال data mining هي اتخاذ قرارات مدعومة

• Data mining is the process that helps in extracting information from a given data set to identify trends, patterns, and useful data.

• The objective of using data mining is to make data-supported decisions from enormous data sets.

→ Different types of data can be mined :-

1. Data stored in database

2. Data Warehouse

3. Transactional data

4. Data streams

5. engineering design

→ The most important data mining techniques.

① association

- discover a link between two or more items.
- it uses if-then statements to show the probability of interactions between data items.

• يبقا هنا ينشوف ارتباط ال items ببعض مثلا في السرد،
لو شحنت هيسترى فون غالباً هيسترى جيراب مثلاً.

② clustering

• يجمع البيانات المتشابهة مع بعض في مجموعات clusters
بحيث كل cluster بيضم بيانات بتشرك في نفس الصنات
• يعتمد على ال unsupervised learning.

• is a data mining technique in which clusters are created of objects that share the same characteristics.

• it is based on unsupervised learning.

• له يجمع البيانات التي تشبه بعض مع بعض
وكن معروفش اسما زه ايه

unsupervised = clustering

supervised = classification

③ classification

• classifies item's in a data set into predefined groups.

• it is based on ~~un~~ supervised learning

الكتاب المكتوب في الكتاب

supervised ولكن ان شاء الله الصبح

predefined groups
كتا قولنا

⇒ The most important Data mining application.

• predictions, classifications, clusters.

• it is used in fields such as:

1- health care

2- Fraud detection in banking transactions.

3- education

4- Market basket analysis

5- Manufacturing and quality.

6- Customer Relationship management.

Data Interpretation تفسير البيانات

بعد ما نحلل البيانات، ثم نقدر نفهم معناها ونوصل لاستنتاجات مفيدة.

Qualitative نوعي

- Relies on analyzing non-numerical data (pictures, symbols)
- We use it when you want to understand patterns and behaviors without clear numbers.

Quantitative كمّي

- Relies on analyzing numerical data with numbers and statistics.
- We use mathematical methods such as
 - 1- mean
 - 2- standard deviation
 - 3- Regression